수율(Yield) 분석이나 공정 최적화

반도체 현업에서 데이터 사이언티스트들이 수율(Yield) 분석이나 공정 최적화를 위해 사용하는

표준적인 작업에 대한 설명 입니다

---

0. 주요 용어 설명

- **도메인 (Domain):** 지식의 전문 분야를 뜻합니다. 반도체 도메인이라 함은 공정 과정, 물리적 특성, 계측 장비의 원리 등 반도체 제조 산업의 특수 지식을 의미합니다.
- **피처 (Feature):** 머신러닝 모델의 **입력값(X)** 입니다. 공정 온도, 압력, 가스 유량, WAT 계측값 등이 이에 해당합니다.
- **타겟 (Target):** 모델이 예측하려는 **결과값(y)**입니다.
- **상관계수 (Correlation Coefficient):** 두 변수 사이의 선형적 관계를 -1에서 1 사이로 나타낸 수치입니다. 1에 가까울수록 양의 상관관계, -1은 음의 상관관계, 0은 무관함을 뜻합니다.
- **알고리즘 (Algorithm):** 데이터를 학습하여 규칙을 찾아내는 논리적 구조 library 입니다.

```
models = {
"LinearRegression": LinearRegression(),
"Ridge": Ridge(alpha=1.0),
"Lasso": Lasso(alpha=0.1),
"DecisionTree": DecisionTreeRegressor(max_depth=5, random_state=42),
"RandomForest": RandomForestRegressor(n_estimators=100,
random_state=42),
"XGBoost": XGBRegressor(n_estimators=100, learning_rate=0.1,
random_state=42),
"LightGBM": LGBMRegressor(n_estimators=100, learning_rate=0.1,
random_state=42)
}
```

---

1. 데이터 수집 및 전처리

1) 5개 엑셀 병합

```
for i in range(1,6):  # excel file 번호
    all_sheets = pd.read_excel(f"data1/Raw data_ref_C_EX{i}.xlsx",
                               sheet_name=None, header=None)
    df_t=pd.DataFrame([])
    #  전체 list columns으로 합친다
    sheetList= list(all_sheets.keys())[:5] # 'Item 설명' 제외
    for key in sheetList:
```

2) 컬럼명 재구성

상위 2개 행을 합치는 작업은 반도체 계측 데이터에서 흔히 발생합니다. (예: 단위와 항목명이 나누어진 경우)

```
df_all_t.columns=[c1 + c2  if c1=='' or c2 == '' else c1 + "_"+ c2 for c1, c2 in zip(col1, col2)]
```

3) 수치형 데이터만 선택 (float)

```
df_all_t=df_all_t.convert_dtypes() # 자료마다 type변경을 한다
   all_df = df_all_t.select_dtypes(include='number')
```

---

2. 피처 엔지니어링 (Feature Engineering)

1) 도메인 전문가의 판단

반도체 현업 전문가가 물리적으로 불가능한 조합이나 중복된 장비 파라미터를 미리 제거하는 단계입니다. 이는 모델의 노이즈를 줄이는 데 가장 중요합니다.

3) 상관계수 기반 필터링 : 초기 필터링

데이터가 너무 많을 때 **다중공선성(Multicollinearity)**을 피하기 위해 수행합니다.

- **고상관 피처 제거 (`highcorr_pro`):** 피처끼리 0.9 이상이면 같은 정보를 가진 것이므로 하나를 제거합니다.
- **저상관 피처 제거 (`targetcorr_pro`):** target과 관계가 0.2 이하인 피처는 예측에 도움이 안 될 확률이 높습니다.

---

3. 타겟 선정 및 알고리즘 학습

`select_target` 함수를 통해 예측 목표(예: `BIN1_Prime`)를 정하고, 다양한 회귀 모델로 성능을 비교합니다.

예측 및 모델별 시각화 (`predict_pro`)

다양한 알고리즘을 한 번에 돌려 r2-score 성능을 비교하는 것이 핵심입니다.

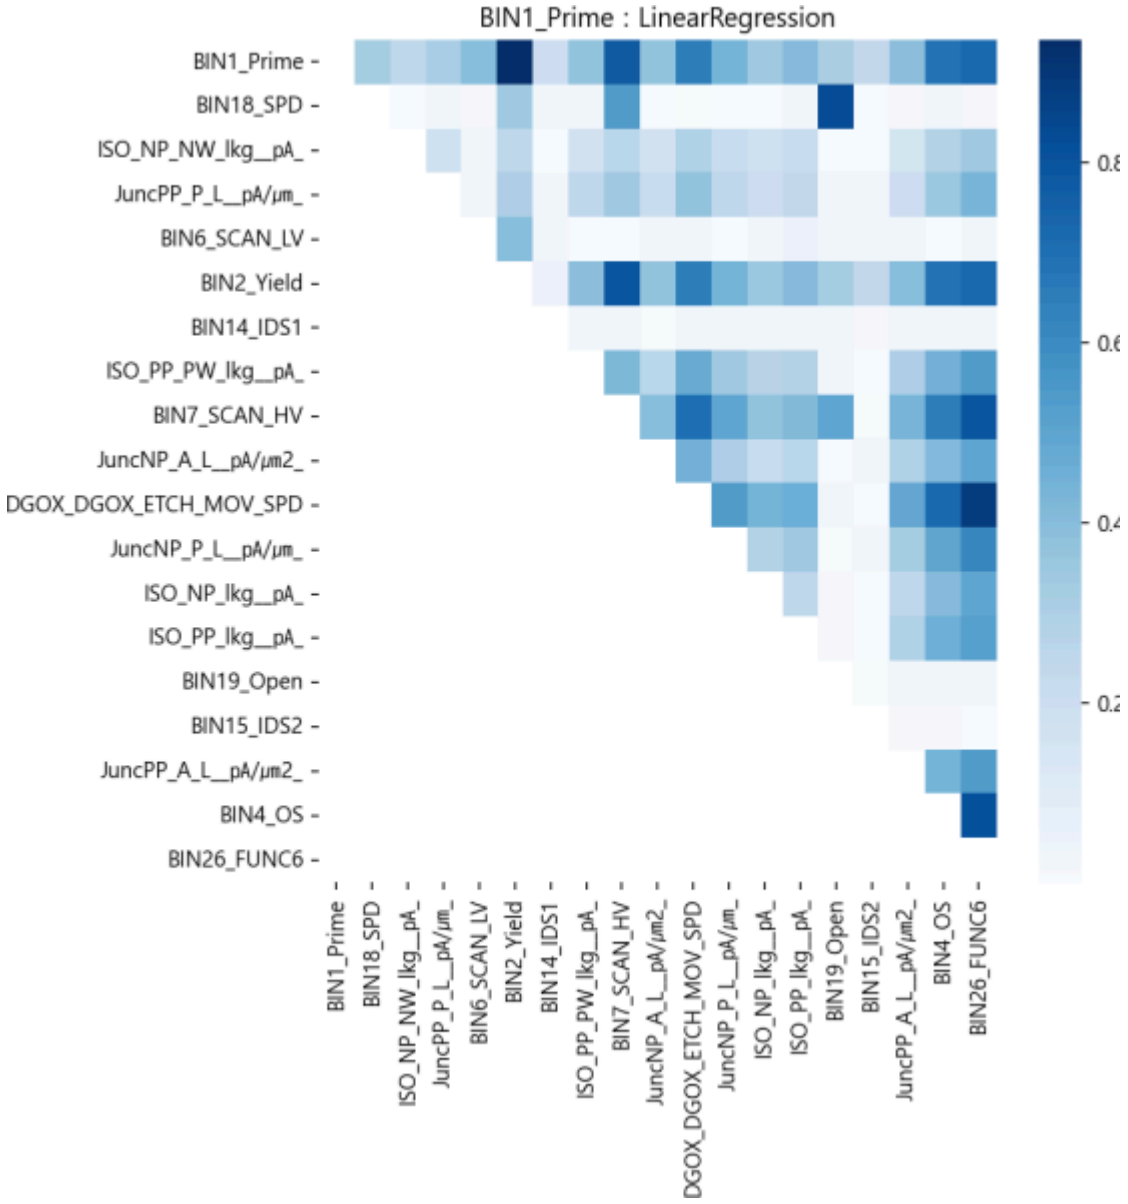

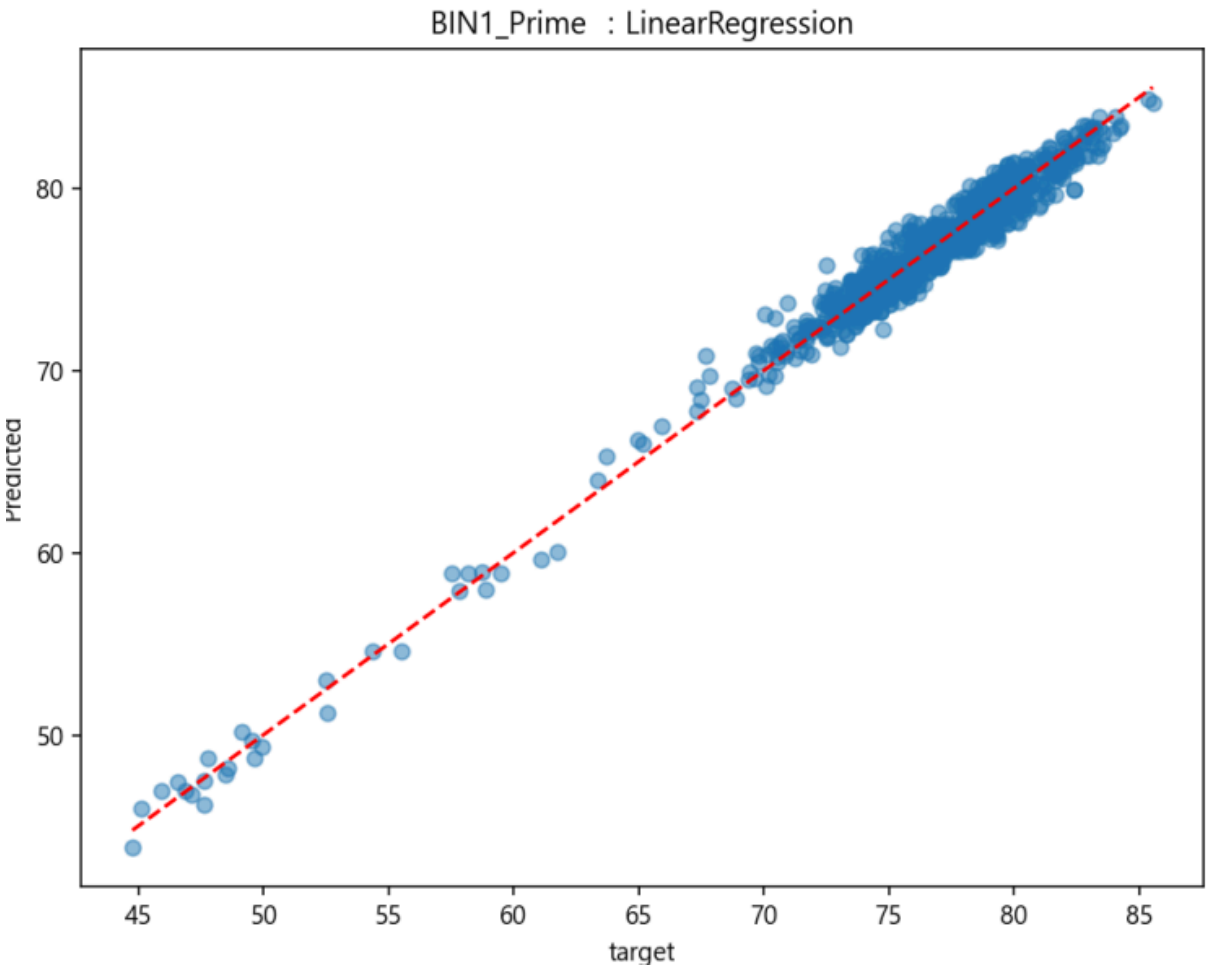
BIN1_Prime : LinearRegression
Predicted
target
80
70
60
50
45
50
55
60
65
70
75
80
85

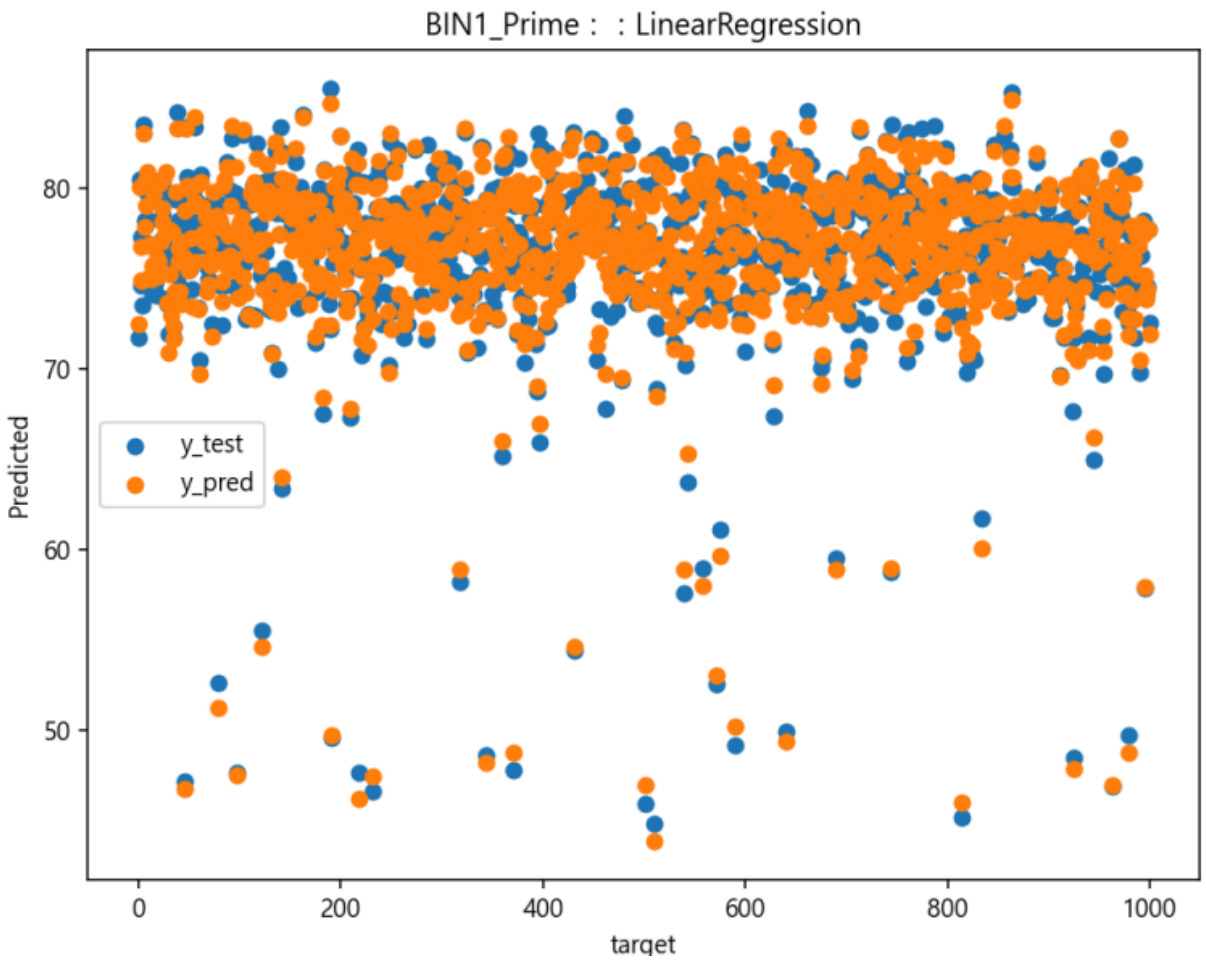

4. 최종 알고리즘 선택

가장 높은 r2-score 를 가진 알고리즘을 선택합니다.

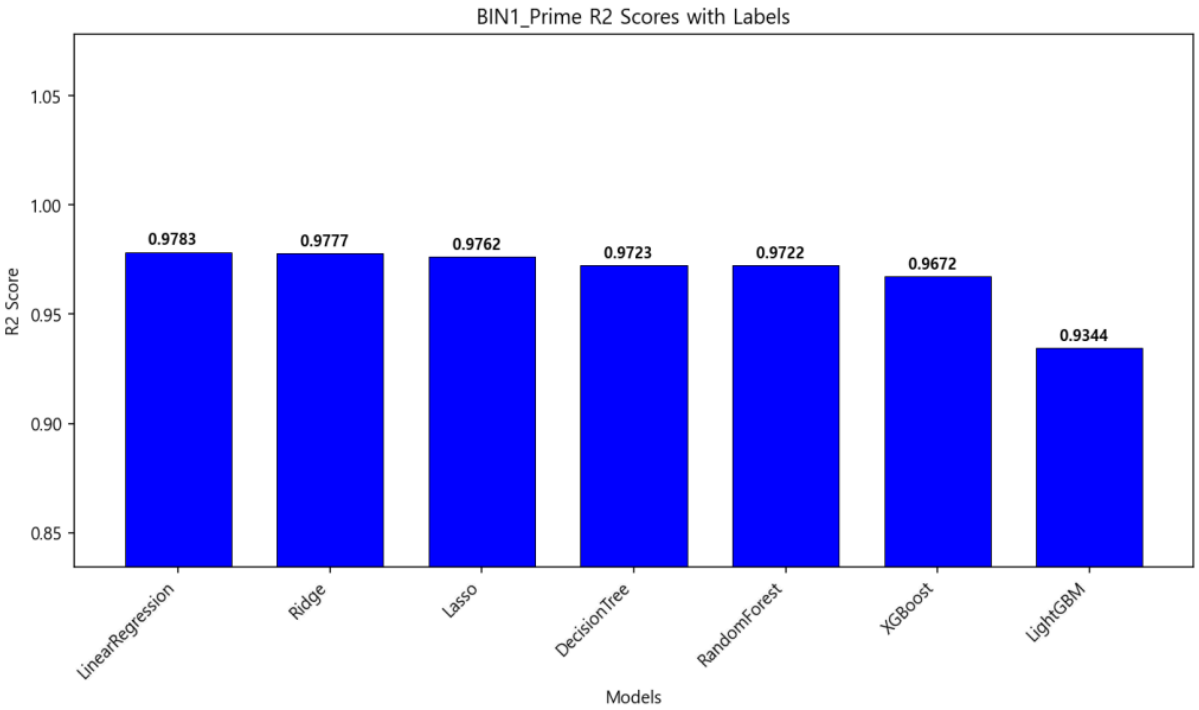

- **주의:** 만약 r2-score 가 1.0에 너무 가깝다면(0.99 이상), **데이터 누수(Data Leakage)**가 없는지 다시 2번 단계로 돌아가 점검해야 합니다.
- **추천:** 반도체 데이터는 비선형적인 경우가 많으므로 `XGBoost` 나 `LightGBM` 이 일반적으로 가장 좋은 성과를 냅니다.