회귀(Regression) 알고리즘

현대 데이터 사이언스에서 가장 자주 사용되는 **회귀(Regression) 알고리즘**들의 핵심 모음집입니다. 이 모델들은 크게 선형 모델, 트리 모델, 그리고 앙상블 모델의 세 가지 그룹으로 나눌 수 있습니다.
각 알고리즘의 특징과 용도를 알기 쉽게 정리해 드릴게요.

1. 선형 모델 (Linear Models)

데이터의 관계를 '직선'으로 파악하려는 모델들입니다. 계산이 빠르고 결과 해석이 쉽다는 장점이 있습니다.

- **LinearRegression (선형 회귀):**
  - **설명:** 가장 기본적인 회귀 모델입니다. 독립 변수와 종속 변수 사이의 선형 관계를 찾습니다.
  - **특징:** 복잡한 데이터에서는 성능이 낮을 수 있지만, 기준점(Baseline)을 잡을 때 필수적입니다.
- **Ridge (릿지):**
  - **설명:** 선형 회귀에 **L2 규제(Regularization)**를 더한 모델입니다.

L2 규제(Regularization) : 모델이 학습 데이터에 너무 과하게 맞춰지는 현상인 **과적합(Overfitting)** 을 방지하기 위해 사용하는 아주 중요한 기법

  - **특징:** 가중치(Weight)들의 크기를 줄여서 모델이 너무 예민해지는 것(과적합)을 방지합니다. 변수 간 상 관관계가 높을 때 유용합니다.
- **Lasso (라쏘):**
  - **설명:** 선형 회귀에 **L1 규제**를 더한 모델입니다.
  - **특징:** 중요하지 않은 변수의 가중치를 아예 **0**으로 만듭니다. 즉, 자동으로 필요한 특징(Feature)만 선택해 주는 효과가 있습니다.

2. 의사결정나무 (Decision Tree)

스무고개 형식으로 데이터를 분류하거나 수치를 예측하는 모델입니다.

- **DecisionTreeRegressor:**
  - **설명:** 데이터를 특정 기준에 따라 계속 가지를 치며 나눕니다.
  - **특징:** 이해하기 매우 쉽고 시각화가 가능하지만, 가지가 너무 많아지면 학습 데이터에만 과하게 최적화 되는 **과적합(Overfitting)** 문제가 잘 발생합니다.

3. 앙상블 모델 (Ensemble Models)

여러 개의 나무(Tree)를 합쳐서 더 강력한 성능을 내는 모델들입니다. 현재 캐글(Kaggle) 등 데이터 경진대회에서 가장 선호되는 방식입니다.

배깅(Bagging) 방식

- **RandomForest:**
  - **설명:** 수많은 의사결정나무를 독립적으로 만들고, 그 결과들의 **평균**을 내어 예측합니다.

- **특징:** 매우 안정적이며, 데이터의 노이즈에 강합니다. 기본 설정값만으로도 꽤 좋은 성능을 보여줍니다.

부스팅(Boosting) 방식

부스팅은 이전 나무가 틀린 부분을 다음 나무가 집중적으로 학습하여 오차를 줄여나가는 방식입니다.

- **XGBoost (Extreme Gradient Boosting):**
  - **설명:** 가디언트 부스팅 알고리즘을 병렬 학습이 가능하도록 최적화한 모델입니다.
  - **특징:** 성능이 매우 뛰어나며 시스템 자원을 효율적으로 사용합니다. 과적합 방지 기능이 내장되어 있습니다.
- **LightGBM:**
  - **설명:** XGBoost보다 속도가 더 빠르고 메모리 사용량이 적은 최신 부스팅 모델입니다.
  - **특징:** 데이터에서 압도적인 속도를 자랑합니다. (다만 데이터 양이 적으면 과적합 위험이 있습니다.)

요약 및 선택 가이드

모델 그룹	특징	추천 상황
선형 모델	단순함, 해석력 높음	데이터가 적거나 관계가 명확할 때
RandomForest	안정적, 과적합 적음	데이터 전처리가 덜 되었거나 기본 성능을 원할 때
XGB/LGBM	높은 정확도, 빠른 속도	데이터가 많고 성능을 최대로 끌어올려야 할 때